

Orientaciones y pautas para el Trabajo Final de Máster (TFM)

Máster en Data Science e Inteligencia Artificial (MDS)

1. Introducción y enfoque del TFM

El Trabajo Final de Máster (TFM) es la culminación del proceso formativo en EBIS. Su objetivo es consolidar las competencias adquiridas mediante la resolución de un problema analítico complejo, transformando datos en valor estratégico.

Filosofía del proyecto

El TFM en el Máster en Data Science e Inteligencia Artificial (MDS) debe cubrir el ciclo de vida completo del dato. No basta con entrenar un modelo; se debe demostrar la capacidad de gestionar el flujo desde la ingesta hasta la visualización. Se espera que el alumno demuestre:

1. **Rigor analítico:** Capacidad para realizar un tratamiento estadístico correcto, evitando sesgos y errores metodológicos en el manejo de datos.
2. **Excelencia técnica:** Código limpio, eficiente y estructurado (Python, R o PySpark), aplicando técnicas avanzadas de *Machine Learning* o *Deep Learning*.
3. **Visión de negocio:** Interpretación de los resultados matemáticos traducidos a decisiones o valor para la organización.

2. Normativa general

- **Formato:** Grupal, manteniendo los grupos de trabajo ya asignados por EBIS, para fomentar *soft skills* de colaboración y simular un equipo de datos real.
- **Tutorización:**
 - Tutor de contenidos asignado.
 - Tutorías grupales semanales y tutorías individuales bajo demanda.
- **Defensa y evaluación:** El corrector asignado del máster será con quien se realizará la defensa y también quien evaluará la entrega.

3. Fases del TFM

Fase 1: La propuesta de proyecto

Antes de comenzar, hay que validar la hipótesis y, sobre todo, la **disponibilidad de los datos**. Los alumnos deben entregar un documento breve (2-3 páginas).

Contenido obligatorio de la propuesta:

1. **Definición del problema:** ¿Qué pregunta de negocio o investigación queremos responder?
2. **Fuente de datos:** ¿De dónde saldrán los datos? (Datasets públicos, APIs, *Web Scraping*, datos empresariales anonimizados). Se debe confirmar que son accesibles y suficientes.
3. **Stack tecnológico y viabilidad de costes:**
 - a. Listado de herramientas, API's y librerías que se prevén utilizar.
 - b. Confirmación explícita de que no existen limitaciones de pago, licencias restrictivas o barreras de acceso (paywalls) que impidan el desarrollo del proyecto.
 - c. Se requiere adjuntar una evidencia de acceso a los datos (captura de pantalla de la conexión a la API, muestra de las primeras filas del CSV o confirmación de descarga).
4. **Naturaleza del problema:** Identificar el objetivo de negocio y la categoría técnica inicial (ej. supervisado: clasificación o regresión). **No es necesario definir el algoritmo final en esta etapa**, la selección del modelo se realizará y justificará durante la fase de experimentación una vez iniciado el módulo de analítica avanzada e inteligencia artificial, que comienza en el tema 15.
5. **Objetivos:** ¿Qué esperamos lograr? (Ej: "Predecir la rotación de clientes con un F1-Score superior al 0.8").

El tutor debe aprobar esta fase, poniendo especial atención en la viabilidad de la obtención de los datos y la ausencia de costes ocultos para evitar bloqueos a mitad del proyecto.

Fase 2: Desarrollo y entregables

El entregable debe ser un proyecto de ciencia de datos reproducible.

A. La solución técnica (código y modelos)

Se debe entregar el código fuente completo que permita replicar el estudio o ejecutar el modelo.

- **Requisito de entrega:** Repositorio en GitHub/GitLab (privado con acceso al tutor). Se admite también la entrega mediante cuadernos de Google Colab, siempre que se garantice la reproducibilidad (acceso a datos) y el orden.
 - Estructura clara (ej: carpetas */data*, */notebooks*, */src*, */models*).
 - Archivo de dependencias (*requirements.txt* o *environment.yml*).
- **Formato del código:** Se admite el uso de *Jupyter Notebooks* para la fase exploratoria y de análisis, pero se valora muy positivamente la refactorización de los procesos de entrenamiento e inferencia en *scripts ".py"* modulares.

- **Nivel:** Debe incluir todo el *pipeline*: Ingesta → Limpieza → Feature Engineering → Modelado → Evaluación.

B. La memoria de proyecto

La memoria deberá tener un **máximo de 60 páginas** donde se detalla la **solución técnica y de negocio**. Dicho documento se deberá **subir en formato PDF** en el espacio indicado en el campus.

Índice estándar recomendado:

1. **Resumen ejecutivo:** Visión global y conclusiones principales en 1 página.
2. **Introducción y objetivos:**
 - Contexto del problema y justificación.
 - **Estado del Arte:** Investigación previa sobre si existen papers, artículos o soluciones similares en la industria, para identificar lecciones aprendidas o modelos de referencia.
3. **Datos y metodología:**
 - Origen de los datos.
 - **EDA (Análisis Exploratorio de Datos):** Visualizaciones clave, estudio de correlaciones, distribución de variables, detección de *outliers*.
 - Preprocesamiento y limpieza (imputación de nulos, normalización, codificación de variables categóricas).
4. **Ingeniería de características (*Feature Engineering*):**
 - Justificación de las variables creadas o seleccionadas para el modelo.
5. **Modelado y experimentación:**
 - Selección de algoritmos (Justificación: ¿Por qué Random Forest y no XGBoost?).
 - Estrategia de entrenamiento (Split Train/Test/Validation, Cross-Validation).
 - Ajuste de hiperparámetros.
6. **Evaluación de resultados:**
 - Métricas de desempeño (Accuracy, ROC-AUC, RMSE, Matrices de confusión, etc.) interpretadas en el contexto del negocio.
 - Comparativa de modelos.
7. **Despliegue o visualización (Opcional pero valorado):**
 - Cómo se consumen los resultados (Dashboard, API, Streamlit).
8. **Conclusiones e impacto.**
 - **Resumen de hallazgos:** Síntesis de los descubrimientos principales tras el análisis y modelado. ¿Se han cumplido los objetivos planteados al inicio? ¿Qué hipótesis se han validado o refutado? ¿Qué variables resultaron ser las más influyentes en el modelo?
 - **Análisis de impacto:** Estimación del ROI (Retorno de Inversión) o cálculo del beneficio esperado (económico u operativo) que supondría la implementación del modelo.
 - Líneas futuras de trabajo.
9. **Bibliografía y anexos.**

Fase 3: Defensa y evaluación

El proceso concluye con una defensa oral ante un evaluador.

- **Duración:** 10 minutos de exposición + 5 minutos de preguntas.
- **Enfoque:**
 - Debe equilibrar la profundidad técnica con la claridad en las conclusiones de negocio.
 - No limitarse a mostrar código, sino mostrar **insights** descubiertos.
- **Material:** Soporte visual obligatorio. Se recomienda mostrar un *dashboard* interactivo o ejecutar una inferencia en tiempo real si el modelo lo permite.

4. Criterios de evaluación

La nota final se compone de la valoración holística de tres pilares:

1. **La solución técnica:**
 - **Calidad del código:** Limpieza, modularidad y reproducibilidad.
 - **Rigor metodológico:** Correcta aplicación de técnicas de validación para evitar *overfitting* o *data leakage*.
 - **Complejidad:** Uso adecuado de las herramientas (Python/R/PySpark) para el volumen y tipo de datos.
2. **La memoria escrita:**
 - Profundidad del Análisis Exploratorio (EDA).
 - Capacidad de interpretar los resultados de los modelos más allá de la métrica pura.
3. **La defensa oral:**
 - Capacidad de síntesis para explicar problemas complejos de forma sencilla.
 - Justificación sólida de las decisiones técnicas tomadas (elección de algoritmos, métricas, etc.).

El valor de un científico de datos no reside únicamente en la ejecución de código, sino en la resolución de problemas. Vuestro TFM debe demostrar capacidad para transformar datos complejos del mundo real en conocimiento estratégico y accionable.